

**FAESA CENTRO UNIVERSITÁRIO
CIÊNCIA DA COMPUTAÇÃO**

**RAFAEL DE OLIVEIRA COSTA
ROBSON SANTOS RODRIGUES**

**VISÃO COMPUTACIONAL E REDES NEURAIS ARTIFICIAIS PARA ENSINAR UM
COMPUTADOR A JOGAR MEGA MAN**

VITÓRIA
2018

RAFAEL DE OLIVEIRA COSTA
ROBSON SANTOS RODRIGUES

**VISÃO COMPUTACIONAL E REDES NEURAIS ARTIFICIAIS PARA ENSINAR UM
COMPUTADOR A JOGAR MEGA MAN**

Projeto de Pesquisa do Trabalho de Conclusão do
Curso de Graduação em Ciência da Computação
apresentado ao Faesa Centro Universitário, sob
orientação do prof. Howard Roatti.

VITÓRIA
2018

SUMÁRIO

1 INTRODUÇÃO	3
1.1 PROBLEMA	3
1.2 FORMULAÇÃO DO PROBLEMA	4
1.3 HIPÓTESE	4
1.4 OBJETIVOS	4
1.4.1 Objetivo Geral	4
1.4.2 Objetivos específicos	4
1.5 JUSTIFICATIVA	5
2 REFERENCIAL TEÓRICO	6
2.1 APRENDIZADO DE MÁQUINA	6
2.2 APRENDIZAGEM PROFUNDA	6
2.3 REDES NEURAIS ARTIFICIAIS	7
2.4 APRENDIZADO POR REFORÇO	7
2.5 VISÃO COMPUTACIONAL	8
2.5.1 OpenCV	9
2.5.2 Python-mss	9
3 METODOLOGIA	10
4 CRONOGRAMA	11
REFERÊNCIAS	12

1 INTRODUÇÃO

Diversos projetos fazem uso de inteligência artificial (IA) para jogar jogos dos mais variados tipos, porém poucos utilizam um meio comum ao ser humano: a visão. O ser humano utiliza a visão para obter informações sobre um jogo qualquer e, com base no que está vendo, toma decisões buscando cumprir seu objetivo.

Com a evolução dos computadores em relação à velocidade de processamento, quantidades maiores de memória e técnicas algorítmicas mais avançadas, é possível pensar em demonstrar um computador jogando videogame imitando o comportamento humano.

O jogo usado para a demonstração foi o *Mega Man 3*, um famoso jogo de plataforma lançado para o console *Nintendo Entertainment System* (NES) no ano de 1990. O jogo funciona de uma forma simples: escolhe-se uma fase, chega-se ao fim da fase passando por inimigos e obstáculos, derrota-se o chefe, e o processo se repete para o restante das fases, variando os obstáculos e inimigos.

Neste trabalho será dada uma demonstração da possibilidade de se ensinar um computador a jogar *videogame* como um ser humano, usando a visão como entrada de dados.

1.1 PROBLEMA

Existem projetos que demonstram a possibilidade de ensinar um computador a jogar *videogame*, como o projeto Marl/O. Nele, um computador é instruído a completar uma fase de *Super Mario World*, coletando informações da memória do emulador e usando como entrada para treinar a Rede Neural que ele possui (SETHBLING, 2015).

O problema proposto por este trabalho é parecido em muita coisa com o Marl/O, no que diz respeito a tomadas de decisão, já que ambos os jogos são de plataforma e o objetivo é chegar ao fim de uma fase. A ideia de como o personagem desse projeto toma as decisões provavelmente será considerada ao longo desse trabalho, sendo usado várias vezes para consulta.

Já na área de visão computacional existe uma variedade enorme de algoritmos e projetos que tem como objetivo a detecção de objetos, necessária para a alimentação do algoritmo de tomada de decisão de controle do personagem.

1.2 FORMULAÇÃO DO PROBLEMA

É possível ensinar o computador a jogar um jogo de *videogame* utilizando como entrada para o processamento somente imagens, de tal maneira a simular, de forma eficiente, o que o ser humano faz?

1.3 HIPÓTESE

É possível desenvolver um programa inteligente que consiga jogar *Mega Man* usando como entrada apenas a tela do jogo, utilizando pra isso técnicas de visão computacional e redes neurais artificiais.

1.4 OBJETIVOS

1.4.1 Objetivo Geral

Desenvolver uma agente inteligente que possa jogar *Mega Man* utilizando como entrada dados obtidos por visão computacional. No fim do experimento, o computador deverá conseguir jogar relativamente bem, evitando danos dos inimigos e desenvolvendo maneiras próprias de derrotar o oponente final da fase.

1.4.2 Objetivos específicos

- Emular o jogo e capturar a tela para utilizá-la em código;
- Aplicar técnicas de visão para processar as imagens obtidas;
- Extrair informações úteis a partir dos dados gerados pela visão;
- Desenvolver uma IA que consiga aprender a lógica do jogo;
- Avaliar o sucesso e o fracasso a partir das informações obtidas pela visão.

1.5 JUSTIFICATIVA

Uma máquina que utiliza a visão e redes neurais para tomar decisões que a leve a cumprir o objetivo de um jogo, poderia usar o mesmo tipo de técnica para realizar outros tipos de tarefas. A demonstração prática desse trabalho visa mostrar que a inteligência artificial atingiu um nível mínimo de maturidade que abre um leque de possibilidades, por exemplo, automatização de seleção de melhores legumes em um processo de separação, carros, caminhões e ônibus autônomos, sistemas de busca por pessoas desaparecidas ligados em uma grande rede de câmeras conectadas ou até mesmo automatizar a compra e venda de ações na bolsa de valores.

2 REFERENCIAL TEÓRICO

Neste capítulo serão evidenciadas algumas teorias e aplicações de conceitos chaves que contribuíram para a elaboração desse projeto.

2.1 APRENDIZADO DE MÁQUINA

Uma área onde o foco de estudo é ensinar ao computador a aprender com base em experiências, por exemplo, imagine a situação de ratos e iscas envenenadas. Ao encontrar um novo alimento com características diferentes, os ratos o comem em menor quantidade. Essa nova alimentação produzirá um estado fisiológico. Se o novo estado for ruim, ou seja, causar mal-estar aos animais, ela será associada a esse estado e, futuramente eles ignorarão qualquer comida com essas características (SHWARTZ; DAVID, 2014, p. 19, tradução nossa).

Analisando essa situação por um lado simplista, e comparando com o computador, bastaria fazê-lo memorizar uma grande quantidade de dados e compará-los a entrada para chegar em um resultado. Mas, e se a entrada não existir no conteúdo armazenado? A diferença dessa abordagem simples com o que os ratos fizeram está na capacidade de generalização. Depois de passarem pela experiência, os ratos conseguem generalizar qualquer entrada (comida). Uma máquina que aprende é aquela que ao ser treinada consegue generalizar qualquer entrada reconhecendo padrões (SHWARTZ; DAVID, 2014, p. 20, tradução nossa).

2.2 APRENDIZAGEM PROFUNDA


Aprendizagem profunda é um subárea de Aprendizado de Máquina. Tem esse nome pois faz uso de múltiplas camadas de processamento no aprendizado. O advento dessa técnica já permitiu ótimos resultados no reconhecimento de fala, detecção de objetos e até mesmo na descoberta de novos medicamentos. Alguns algoritmos de Aprendizagem Profunda como Rede Convolucionais e Redes Recorrentes trouxeram grandes melhorias no campo de IA. O primeiro trouxe melhora no processamento de imagens, vídeos fala e áudio. Enquanto o segundo ajudou a trabalhar com fala e texto. O conjunto dessas camadas é o que forma uma Rede Neural Artificial (LECUN; BENGIO; HINTON, 2015, p. 1, tradução nossa).

2.3 REDES NEURAIS ARTIFICIAIS

Rede Neurais Artificiais se baseiam na teoria do funcionamento do cérebro, em especial os neurônios. É sabido que o cérebro possui um alto poder de processamento, sendo capaz de realizar tarefas como reconhecimento de padrões, percepção e controle motor de tal maneira que nenhum computador ainda consegue fazer. Com o poder computacional existente é possível simular o comportamento cerebral de maneira a realizar uma tarefa específica.

Uma característica interessante do neurônio e muito útil em uma Rede Neural é a sua plasticidade, ou seja, ser capaz de se adaptar ao ambiente. Em Redes Neurais, a conexão maciça desses neurônios é a responsável pela habilidade de se adaptar ao meio. Na Figura 1 é mostrada uma representação simples dos neurônios conectados entre si e organizados em camadas formando uma Rede Neural. (HAYKIN, 2001, p. 27).

Figura 1 – Rede Neural



Fonte: Departamento de Computação – UFOP

2.4 APRENDIZADO POR REFORÇO

Aprendizado por reforço é o problema encarado por um agente que deve aprender um comportamento em um ambiente dinâmico através de tentativa e erro.

Existem duas estratégias principais para resolver problemas de aprendizagem por reforço. A primeira é buscar em um espaço de comportamentos, um que funcione bem no ambiente. Essa estratégia é usada pelos algoritmos genéticos e pela programação genética. A segunda forma é usar técnicas estatísticas e métodos de programação dinâmica para estimar a utilidade de tomar uma ação em determinado estado do mundo.

Em um modelo normal de aprendizagem por reforço, um agente é conectado com um ambiente via sensores e atuadores. Em cada passo de interação, o agente recebe uma entrada i , e algum indicador do estado atual, s , do ambiente. O agente então, escolhe uma ação, a , que gera uma saída. A ação altera o estado do ambiente, e o valor dessa transição de estado é comunicada ao agente através de um sinal de reforço, r . O comportamento do agente deve escolher ações que tendem a aumentar a soma dos sinais de reforço recebidos ao longo do tempo.

O trabalho do agente é encontrar uma política π , mapeando estados para ações, que maximizam alguma medida de reforço a longo prazo (KAELBLING; LITTMAN; MOORE, 1996, p. 238, tradução nossa).

2.5 VISÃO COMPUTACIONAL

Visão computacional é o estudo da extração de informação de uma imagem; mais especificamente, é a construção de descrições explícitas e claras dos objetos em uma imagem. Difere do processamento de imagens porque, enquanto ele se trata apenas da transformação de imagens em outras imagens, a visão computacional trata explicitamente da obtenção e manipulação dos dados de uma imagem e da sua utilização para diferentes propósitos.

Diversos campos estão relacionados à visão computacional. O mais notável é a própria visão biológica, na qual a visão computacional é baseada; Na verdade, é justo dizer que essas são áreas análogas, uma para a computação, outra, para a biologia. Afinal, enquanto o último estuda os processos psicológicos envolvidos na formação e percepção de imagens pelos seres vivos, a computação estuda os processos e algoritmos usados por máquinas para enxergar (RIOS; LUIZ, 2010, p. 1).

A Visão Computacional faz uso de diversos algoritmos de Aprendizagem Profunda como rede neurais profundas, redes neurais profundas convolucionais, redes de crenças profundas e redes neurais recorrentes (LOPES; BRAGA, 2017, p. 10).

2.5.1 OpenCV

Open Source Computer Vision Library(OpenCV) é uma biblioteca de código aberto criada para auxiliar trabalhos no campo de visão computacional e *machine learning*. Conta com vários algoritmos altamente otimizados, escritos em C/C++. Alguns usam processamento *multi-core* para garantir um tempo de resposta ótimo. Ideal para aplicações em tempo real.

A biblioteca tem mais de 2500 algoritmos, o que inclui um conjunto abrangente de visão computacional e de aprendizado de máquina clássicos e de última geração (ABOUT..., [2018?], tradução nossa).

2.5.2 Python-mss

É uma biblioteca de código aberto que disponibiliza funções ultrarrápidas de captura de múltiplas telas (WELCOME..., [2018?], tradução nossa).

3 METODOLOGIA

Nesse trabalho será realizada uma pesquisa exploratória que visa fazer uma revisão bibliográfica de conteúdos relacionados ao tema. Atualmente existem diversas técnicas e ferramentas que auxiliam na aplicação da Inteligência Artificial, porém foi necessário separar alguns assuntos e métodos que demonstram mais relevância no cenário atual e, boa parte do conteúdo foi retirado de livros e artigos em sua maioria em inglês, em parte devido à dificuldade de se encontrar conteúdo em português.

Para trabalhar com as imagens serão utilizadas as bibliotecas Python-mss e OpenCV. Por meio da Python-mss serão obtidos *frames* que irão ser processados pela OpenCV de modo a obter informações relevantes sobre cada quadro de vídeo. Essas informações serão utilizadas por algoritmos de IA para tomada de decisão. O agente deverá explorar o ambiente e ser recompensando por determinada ação. Caso ele receba algum dano e perca pontos de vida será recompensando negativamente, caso chegue o mais longe sem receber danos será recompensado positivamente, aprendendo por reforço.

O fluxo de captura, processamento e decisão será contínuo. Ao final de tudo, os resultados serão mensurados de maneira quantitativa, de modo a avaliar o desempenho do algoritmo desenvolvido.

4 CRONOGRAMA

[illegible]

REFERÊNCIAS

- HAYKIN, S. **Redes Neurais: Princípios e Prática**. 2ª Edição. Porto Alegre. Bookman. 2011. 898 p.
- Kaelbli, L. P.; Littman, M. L.; Moore, A. W. **Reinforcement Learning: A Survey**. Disponível em: <https://www.cs.cmu.edu/~tom/10701_sp11/slides/Kaelbling.pdf>. Acessado em: 20 out. 2018.
- LECUN, Y.; BENGIO, Y.; HINTON, G. **Deep learning**. Disponível em: <https://creativecoding.soe.ucsc.edu/courses/cs523/slides/week3/DeepLearning_LeCun.pdf>. Acessado em: 12 nov. 2018.
- LOPES, Rafael A. S.; BRAGA, Victor Gueresi de Mello. **Um Sistema para o Aprendizado Automático de Jogos Eletrônicos Baseado em Redes Neurais e Q-Learning usando Interface Natural**. Disponível em: <http://bdm.unb.br/bitstream/10483/17240/1/2017_RafaelLopes_VictorGueresi_tc.c.pdf>. Acesso em: 07 out. 2018.
- OPENCV. **About**. Disponível em: <<https://www.opencv.org/about.html>>. Acesso em: 10 out. 2018.
- PYTHON-MSS. **Welcome to Python MSS's documentation!**. Disponível em: <<https://python-mss.readthedocs.io/>>. Acesso em: 10 out. 2018.
- RIOS, L. R. S. **Visão Computacional**. Disponível em: <[http://homes.dcc.ufba.br/~luizromario/Apresenta%C3%A7%C3%A3o%20de%20IA/Artigo%20\(final\).pdf](http://homes.dcc.ufba.br/~luizromario/Apresenta%C3%A7%C3%A3o%20de%20IA/Artigo%20(final).pdf)>. Acesso em: 25 out. 2018.
- SETHBLING. **Marl/O - Machine Learning for Video Games**. 2015. (5m57s). Disponível em: <<https://www.youtube.com/watch?v=qv6UVOQ0F44&t=1s>>. Acesso em: 21 out. 2018.
- SHALEV-SHWARTZ, S. ; BEN-DAVID S. **Understanding Machine Learning: From Theory to Algorithms**. 1ª Edição. Cambridge. Cambridge University Press. 2014. 410 p.